



Contemporânea

Contemporary Journal

Vol. 5 Nº. 6: p. 01-17, 2025

ISSN: 2447-0961

Artigo

ANÁLISE E PREVISÃO DE TENDÊNCIAS NO MERCADO FINANCEIRO ATRAVÉS DO PROCESSAMENTO DE LINGUAGEM NATURAL

ANALYSIS AND FORECASTING OF FINANCIAL MARKET TRENDS THROUGH NATURAL LANGUAGE PROCESSING

ANÁLISIS Y PREDICCIÓN DE TENDENCIAS EN EL MERCADO FINANCIERO A TRAVÉS DEL PROCESAMIENTO DEL LENGUAJE NATURAL

DOI: 10.56083/RCV5N6-033

Receipt of originals: 5/9/2025

Acceptance for publication: 5/30/2025

Lucas Martins Jesus Oliveira

Graduando em Sistemas de Informação, área de TI

Instituição: Instituto Federal Goiano - campus Ceres

Endereço: São Patrício, Goiás, Brasil

E-mail: lucasmartinsjoliveira@gmail.com

RESUMO: O mercado financeiro contemporâneo é caracterizado por elevada complexidade, volatilidade e influência de fatores qualitativos não estruturados, como notícias, relatórios e redes sociais. Diante da crescente demanda por ferramentas preditivas mais sensíveis e eficazes, este estudo tem como objetivo avaliar o potencial do Processamento de Linguagem Natural (PLN) na análise e previsão de tendências financeiras. Fundamentado em uma abordagem teórica e exploratória, o trabalho revisa criticamente os métodos tradicionais de previsão, como análises fundamentalista, técnica e modelos econométricos, destacando suas limitações diante da explosão de dados textuais. A pesquisa aborda o uso de técnicas de PLN, como análise de sentimentos, classificação textual e modelos baseados em redes neurais profundas (LSTM, BERT), explorando seu uso na extração de padrões linguísticos que antecipam movimentos de mercado. Os resultados apontados pela literatura indicam que tais técnicas ampliam a capacidade de previsão, especialmente em contextos de alta imprevisibilidade. Além disso, o estudo discute os desafios éticos e técnicos associados ao uso de



algoritmos, como vieses estruturais e falta de transparência dos modelos. Conclui-se que a integração entre PLN e modelos preditivos representa uma inovação promissora no campo das finanças, contribuindo para decisões mais informadas e contextualizadas, embora demande constante aperfeiçoamento técnico e reflexão crítica quanto à sua aplicação prática.

PALAVRAS-CHAVE: mercado financeiro, previsão, linguagem natural, análise de sentimentos, inteligência artificial, tendências econômicas.

ABSTRACT: The contemporary financial market is characterized by high complexity, volatility, and the influence of unstructured qualitative factors such as news, reports, and social media. In response to the growing demand for more sensitive and effective predictive tools, this study aims to assess the potential of Natural Language Processing (NLP) in the analysis and forecasting of financial trends. Based on a theoretical and exploratory approach, the research critically reviews traditional forecasting methods, such as fundamental, technical, and econometric analyses, highlighting their limitations in the face of the explosion of textual data. The study explores the use of NLP techniques such as sentiment analysis, text classification, and deep neural network models (LSTM, BERT), examining their application in extracting linguistic patterns that anticipate market movements. Findings from the literature indicate that these techniques enhance forecasting capabilities, especially in highly unpredictable contexts. Additionally, the study discusses ethical and technical challenges related to algorithm use, such as structural biases and lack of transparency in models. It concludes that the integration of NLP and predictive models represents a promising innovation in the financial sector, supporting more informed and contextualized decisions, while requiring continuous technical refinement and critical reflection on its practical applications.

KEYWORDS: financial market, forecasting, natural language, sentiment analysis, artificial intelligence, economic trends.

RESUMEN: El mercado financiero contemporáneo se caracteriza por una alta complejidad, volatilidad e influencia de factores cualitativos no estructurados, como noticias, informes y redes sociales. Ante la creciente demanda de herramientas predictivas más sensibles y eficaces, este estudio tiene como objetivo evaluar el potencial del Procesamiento del Lenguaje Natural (PLN) en el análisis y la predicción de tendencias financieras. Basado en un enfoque teórico y exploratorio, el trabajo revisa críticamente los métodos tradicionales de previsión, como el análisis fundamental, técnico y los modelos econométricos, destacando sus limitaciones frente a la explosión de datos textuales. La investigación aborda el uso de técnicas de PLN, como el análisis de sentimientos, la clasificación textual y los modelos basados en



redes neurais profundas (LSTM, BERT), explorando sua aplicação na extração de padrões linguísticos que antecipam movimentos do mercado. Os resultados sinalizados por a literatura indicam que estas técnicas ampliam a capacidade de predição, especialmente em contextos de alta imprevisibilidade. Além disso, o estudo discute os desafios éticos e técnicos associados com o uso de algoritmos, como os vieses estruturais e a falta de transparência dos modelos. Se conclui que a integração entre PLN e modelos preditivos representa uma inovação prometedora em o campo das finanças, contribuindo para decisões mais informadas e contextualizadas, embora exija uma melhoria técnica constante e uma reflexão crítica sobre sua aplicação prática.

PALAVRAS CHAVE: mercado financeiro, predição, linguagem natural, análise de sentimentos, inteligência artificial, tendências econômicas.



Artigo está licenciado sob forma de uma licença
Creative Commons Atribuição 4.0 Internacional.

1. Introdução

O mercado financeiro é caracterizado por sua alta volatilidade e pela contínua evolução dos métodos de análise e previsão de tendências, com o advento de grandes volumes de informações não estruturadas, como notícias, relatórios corporativos e publicações em redes sociais, tornou-se imperativo desenvolver técnicas capazes de transformar esse conteúdo textual em insumos analíticos confiáveis.

Nesse contexto, o Processamento de Linguagem Natural (PLN) surge como tecnologia estratégica, permitindo extrair indicadores de sentimento, opinião e relevância que complementam ou até mesmo superam os métodos tradicionais de previsão baseados exclusivamente em séries históricas de preços.

Apesar dos avanços em modelos quantitativos e econométricos, observa-se uma lacuna na incorporação sistemática de variáveis qualitativas de natureza textual nos processos de tomada de decisão financeira, os



estudos pioneiros (Bollen *et al.*, 2011; Tetlock, 2007) demonstram a correlação entre o “humor” extraído de redes sociais e manchetes jornalísticas e os movimentos dos principais índices de ações.

No entanto, a adoção prática de PLN por investidores e instituições financeiras ainda é incipiente, em boa parte devido à complexidade da metodologia e à falta de diretrizes claras para sua aplicação em cenários reais.

Diante desse panorama, esta pesquisa se propõe a investigar, de forma teórica e aplicada, como o PLN pode ser utilizado para analisar e prever tendências no mercado financeiro, avaliando seus benefícios, desafios e limitações. A questão central que orienta este estudo é: Em que medida as técnicas de Processamento de Linguagem Natural contribuem para aumentar a precisão das previsões de tendências no mercado financeiro, em comparação com métodos convencionais?

A justificativa deste trabalho apoia-se na necessidade de oferecer aos profissionais de finanças um referencial consolidado sobre práticas e modelos de PLN, bem como na oportunidade de demonstrar sua aplicabilidade como ferramenta de apoio à decisão, especialmente em cenários de alta complexidade e incerteza, além disso, ao sistematizar as abordagens existentes e apontar seus principais desafios éticos e técnicos, pretende-se contribuir para orientar pesquisas futuras e o desenvolvimento de soluções mais robustas e transparentes.

O objetivo geral foi: avaliar teoricamente o potencial do Processamento de Linguagem Natural para aprimorar a previsão de tendências no mercado financeiro. Ao passo que os objetivos específicos: revisar os principais métodos tradicionais e quantitativos de previsão financeira e identificar suas limitações diante de dados não estruturados; mapear as técnicas de PLN, incluindo análise de sentimento, extração de tópicos e modelos de *deep learning*, aplicáveis ao contexto financeiro; comparar criticamente, a partir da literatura, a eficácia de abordagens baseadas em PLN em relação a



modelos convencionais e discutir as implicações éticas, técnicas e de vies associadas ao uso de PLN em decisões de investimento.

2. Referencial Teórico

2.1 Mercado Financeiro: Fundamentos e Dinâmicas

O mercado financeiro pode ser definido como o ambiente no qual se realizam negociações de ativos financeiros, como ações, títulos públicos, moedas estrangeiras e derivativos, de acordo com Assaf Neto (2021), trata-se de um conjunto de instituições, agentes, instrumentos e operações que viabilizam o fluxo de recursos entre poupadores e tomadores de recursos, promovendo a alocação eficiente do capital.

Esse mercado divide-se em quatro grandes segmentos, quais sejam, o mercado monetário, onde ocorrem operações de curtíssimo prazo, o mercado de crédito, voltado à concessão de empréstimos; o mercado de capitais, que trata da emissão e negociação de ações e debêntures, e o mercado de câmbio, no qual são negociadas moedas estrangeiras.

Segundo Gitman e Zutter (2010), a estrutura do mercado financeiro é essencial para o desenvolvimento econômico, pois estimula o investimento produtivo e contribui para a estabilidade do sistema.

Os ativos financeiros representam títulos ou contratos que conferem direitos sobre fluxos de caixa futuros, segundo Fabozzi (2013), eles se dividem em ativos de renda fixa (como títulos públicos, CDBs e debêntures) e ativos de renda variável (como ações e cotas de fundos), os instrumentos financeiros também incluem derivativos, como opções e contratos futuros, que permitem operações de proteção (*hedge*), alavancagem e especulação.

Cada tipo de ativo possui características distintas quanto à liquidez, risco e rentabilidade, para Damodaran (2012), o entendimento profundo desses instrumentos é essencial para a tomada de decisão no mercado, pois



permite ao investidor compor uma carteira diversificada e alinhada ao seu perfil de risco.

As tendências de mercado são impactadas por uma variedade de fatores econômicos, políticos, sociais e até comportamentais, conforme Malkiel (2019), o comportamento dos preços dos ativos pode ser influenciado por variáveis macroeconômicas (como taxa de juros, inflação e PIB), eventos geopolíticos, decisões de política monetária e fiscal, além de expectativas dos agentes econômicos.

Outro aspecto relevante é o papel da informação, de acordo com Fama (1970), em mercados eficientes os preços refletem toda a informação disponível. No entanto, estudos posteriores, como os de Shiller (2003), indicam que fatores comportamentais e emocionais também exercem influência, o que explica flutuações não totalmente racionais nos preços dos ativos, assim, o monitoramento constante dessas variáveis torna-se imprescindível para a antecipação de tendências e a mitigação de riscos.

A análise de tendências no mercado financeiro é uma ferramenta estratégica tanto para investidores individuais quanto para instituições, segundo Murphy (1999), compreender a direção predominante dos preços ao longo do tempo permite identificar oportunidades de entrada ou saída do mercado, além de aprimorar a gestão de riscos.

Além disso, a análise de tendências não se limita à análise técnica dos gráficos, mas pode ser potencializada com métodos quantitativos e tecnologias de Processamento de Linguagem Natural (PLN), como destaca López de Prado (2018), com o uso de inteligência artificial, torna-se possível captar sinais de mercado em dados não estruturados, como notícias e redes sociais, oferecendo *insights* mais dinâmicos e abrangentes.

Instituições financeiras, fundos de investimento e grandes corporações utilizam essas análises para tomada de decisão estratégica, projeção de cenários e alocação de recursos, segundo Damodaran (2012), a habilidade de interpretar tendências e precificar adequadamente os ativos constitui uma



vantagem competitiva no ambiente volátil e globalizado dos mercados contemporâneos.

2.2 Previsão de Tendências no Mercado Financeiro

A previsão de tendências no mercado financeiro sempre foi uma atividade central para investidores, analistas e instituições, tradicionalmente, essa previsão se baseia em duas grandes abordagens, a análise fundamentalista e a análise técnica.

A análise fundamentalista busca identificar o valor intrínseco dos ativos com base em indicadores econômicos, financeiros e contábeis, conforme Graham e Dodd (1934), esse método se sustenta na premissa de que o valor real de uma empresa será refletido em seu preço de mercado ao longo do tempo, os indicadores como lucro por ação, fluxo de caixa, endividamento e perspectivas macroeconômicas são amplamente utilizados.

Já a análise técnica, também chamada de análise gráfica, estuda o comportamento passado dos preços e volumes negociados para identificar padrões e tendências futuras, segundo Murphy (1999), esse método parte do pressuposto de que os preços descontam todas as informações disponíveis e que o comportamento do mercado se repete em padrões identificáveis, como suportes, resistências, topos e fundos.

Ambos os métodos são amplamente utilizados, porém apresentam limitações, especialmente em ambientes altamente voláteis ou influenciados por eventos não econômicos.

Com o avanço da ciência de dados e da estatística aplicada às finanças, surgiram os modelos quantitativos e econométricos como alternativa ou complemento aos métodos tradicionais, tais modelos utilizam equações matemáticas para identificar relações entre variáveis e prever comportamentos futuros com base em dados históricos.



Entre os modelos mais utilizados estão as séries temporais autoregressivas (ARIMA, SARIMA), os modelos GARCH para volatilidade, e os modelos de regressão múltipla, segundo *Brooks* (2014), tais modelos são eficazes para estimar retornos, volatilidade e risco, desde que as premissas estatísticas sejam respeitadas, como estacionariedade e ausência de multicolinearidade.

Além disso, modelos como o *Value at Risk* (VaR) e o *Capital Asset Pricing Model* (CAPM) são amplamente utilizados por instituições financeiras para análise de risco e precificação de ativos (Hull, 2015).

Contudo, conforme apontado por Tsay (2010), esses modelos são sensíveis a rupturas estruturais nos dados e assumem linearidade e distribuição normal, o que pode não refletir a realidade de um mercado financeiro dinâmico e influenciado por múltiplas variáveis exógenas.

Embora os métodos tradicionais e quantitativos tenham papel relevante na história da previsão financeira, enfrentam limitações significativas no contexto atual, uma das principais críticas é a incapacidade de capturar informações não estruturadas e variáveis qualitativas, como sentimento de mercado, rumores, opiniões de especialistas ou impactos reputacionais.

Segundo Shiller (2003), os mercados são influenciados por fatores irracionais e psicológicos, que escapam à lógica dos modelos estatísticos tradicionais, os eventos imprevisíveis (como crises sanitárias, guerras ou mudanças políticas abruptas) afetam o mercado sem que haja um padrão histórico que os antecipe de maneira confiável.

Além disso, conforme López de Prado (2018), muitos modelos tradicionais sofrem de *overfitting* e assumem um ambiente estático e racional, enquanto o mercado real é caótico, reativo e guiado também por fatores emocionais captados apenas por meio de dados qualitativos, como os textos de redes sociais, pronunciamentos oficiais ou manchetes jornalísticas.



A crescente disponibilidade de dados não-estruturados, como notícias, relatórios, publicações em redes sociais e fóruns de investidores, impulsionou a adoção de técnicas inovadoras de previsão baseadas em Processamento de Linguagem Natural (PLN) e Inteligência Artificial (IA).

Segundo Kearney e Liu (2014), a análise de sentimento derivada de textos financeiros é capaz de antecipar movimentos do mercado ao captar o “humor” dos investidores, tal abordagem permite detectar oscilações antecipadas no comportamento dos preços com base na reação emocional dos agentes de mercado, superando as limitações da análise puramente numérica.

Aliando PLN a algoritmos de *machine learning*, como SVM, redes neurais, LSTM e transformers (como BERT), é possível treinar modelos preditivos com capacidade adaptativa e em tempo real. Conforme Hu, Liu e Skiena (2004), tais modelos têm mostrado resultados promissores ao analisar grandes volumes de dados textuais e identificar correlações entre expressões linguísticas e oscilações no mercado financeiro.

Além disso, López de Prado (2018) defende que, ao incorporar dados alternativos (*alternative data*), como texto, imagem e áudio, os analistas financeiros podem construir modelos preditivos mais robustos, sensíveis ao contexto e com maior capacidade de antecipação de crises e oportunidades.

2.3 Aplicações do PLN na Análise Financeira e Integração do PLN com Modelos de Previsão

A análise de sentimentos, ou *sentiment analysis*, consiste na identificação automática da polaridade (positiva, negativa ou neutra) de textos relacionados a ativos financeiros, com o objetivo de antecipar movimentos do mercado, de acordo com Liu (2012), essa técnica utiliza o Processamento de Linguagem Natural (PLN) para transformar dados textuais em indicadores quantitativos, capazes de representar o humor do mercado.



Bollen, Mao e Zeng (2011) demonstraram que o sentimento extraído de postagens no *Twitter* possui correlação estatisticamente significativa com o desempenho de índices como o *Dow Jones Industrial Average* (DJIA), sugerindo que o comportamento coletivo pode ser capturado e transformado em previsões econômicas.

A análise de sentimentos também é utilizada por gestores de fundos e *traders* para captar mudanças abruptas no humor dos investidores antes que estas se manifestem nos preços dos ativos, funcionando como um sistema de alerta precoce (Zhang *et al.*, 2020).

As notícias financeiras são fontes primárias de informação para investidores e agentes de mercado, o uso de PLN permite automatizar a leitura, classificação e avaliação de impacto dessas notícias sobre os ativos.

De acordo com Tetlock (2007), notícias com conteúdo linguístico mais pessimista tendem a provocar queda nos preços das ações, independentemente da presença de dados numéricos objetivos, a aplicação de modelos de *text mining* possibilita classificar manchetes ou artigos conforme seu impacto provável (positivo, negativo ou neutro), gerando *scores* que alimentam modelos de decisão automática.

Recentemente, estudos como o de Kogan *et al.* (2009) demonstraram que informações contidas em relatórios financeiros e artigos jornalísticos podem ser mais preditivas do que os próprios fundamentos contábeis tradicionais, desde que analisadas por técnicas avançadas de PLN.

Com a ascensão das redes sociais, plataformas como *Twitter*, *Reddit* (especialmente o fórum *WallStreetBets*) e *LinkedIn* se tornaram fontes relevantes para análise de tendências em tempo real, segundo Oliveira *et al.* (2017), a extração e análise desses dados oferece *insights* sobre comportamentos emergentes, rumores de mercado, percepção de risco e até possíveis manipulações de preço.

A capacidade de analisar em tempo real grandes volumes de mensagens curtas e informais exige o uso de arquiteturas de PLN robustas,



como *transformers* e *streaming data processing*, como afirma Ranco *et al.* (2015), existe uma relação direta entre o volume de *tweets* mencionando empresas e o volume de transações no mercado financeiro, o que justifica a relevância dessa aplicação.

As grandes instituições financeiras, como a Bloomberg, J.P. Morgan e Goldman Sachs, já implementam soluções de PLN em suas operações, a Bloomberg, por exemplo, desenvolveu o sistema Bloomberg Terminal, que utiliza PLN para oferecer alertas automáticos com base na análise de manchetes em tempo real.

Segundo López de Prado (2018), os fundos quantitativos utilizam estratégias baseadas em *news sentiment scores*, cruzando-os com dados de mercado para gerar sinais de compra ou venda. O Barclays, por sua vez, adotou algoritmos de *sentiment analysis* para avaliar transcrições de teleconferências de resultados trimestrais, a fim de identificar padrões emocionais não verbalizados, como hesitações ou insegurança dos executivos (Jagadeesh & Wu, 2013).

A combinação de PLN com algoritmos de aprendizado de máquina (*machine learning*) permite a construção de sistemas preditivos mais precisos, baseados em informações estruturadas (como preços e volumes) e não estruturadas (como textos).

Segundo Bishop (2006), o uso de algoritmos supervisionados como *Support Vector Machines (SVM)*, *Random Forests* e *Gradient Boosting* é eficaz para classificar sentimentos extraídos de textos e correlacioná-los com movimentos futuros dos ativos, tal abordagem tem sido amplamente adotada por *quant funds* e *startups* de tecnologia financeira (*fintechs*).

As redes neurais profundas, especialmente os modelos LSTM (*Long Short-Term Memory*) e transformers como o BERT (*Bidirectional Encoder Representations from Transformers*), revolucionaram a capacidade de previsão textual.



O LSTM, como descrito por Hochreiter e Schmidhuber (1997), é eficaz na modelagem de sequências temporais, o que a torna ideal para prever séries financeiras com base em textos cronológicos, já o BERT, desenvolvido por Devlin *et al.* (2018), permite contextualizar cada palavra em relação a todas as outras da frase, oferecendo uma compreensão semântica superior.

Esses modelos têm sido treinados com grandes volumes de textos financeiros e aplicados com sucesso para prever variações de ativos, volatilidade e risco sistêmico (Yang *et al.*, 2020).

3. Metodologia

O estudo caracteriza-se como uma pesquisa aplicada, de natureza quantitativa e qualitativa, com abordagem exploratória e descritiva, essa escolha permite não apenas identificar padrões e relações entre as variáveis envolvidas, mas também interpretar os fenômenos com base em dados empíricos e textuais extraídos de fontes reais do mercado financeiro.

A amostra foi composta por documentos textuais não estruturados, como manchetes de notícias financeiras, publicações em redes sociais e relatórios corporativos, coletados por meio de plataformas automatizadas e APIs de acesso público, a seleção dos dados levou em consideração critérios de atualidade, relevância temática e volume representativo, visando garantir a consistência e a abrangência das análises.

4. Resultados e Discussões

As investigações teóricas na área convergem para a constatação de que a integração entre PLN e modelos de aprendizado de máquina representa uma ruptura metodológica em relação às abordagens tradicionais.

Segundo Liu (2012), a análise de sentimentos constitui um dos principais eixos de aplicação do PLN no setor financeiro, permitindo



transformar conteúdos textuais, como manchetes, relatórios corporativos ou postagens em redes sociais, em indicadores quantitativos de humor do mercado, tal técnica, quando bem calibrada, contribui para antecipar movimentos de ativos e avaliar riscos reputacionais.

Bollen, Mao e Zeng (2011), em um dos estudos mais citados da área, demonstraram que o sentimento predominante no *Twitter* antecede oscilações nos índices do mercado de ações norte-americano, essa constatação reforça a tese de que as emoções coletivas, mesmo expressas informalmente, influenciam decisões financeiras em escala global.

A análise de notícias financeiras, por sua vez, tem sido amplamente estudada como fator de influência direta na variação de preços dos ativos, Tetlock (2007) evidenciou que o uso de linguagem negativa em colunas de opinião financeira tende a induzir pessimismo no mercado, resultando em desvalorização de ações. Kogan *et al.* (2009) avançam nesse ponto ao argumentar que a linguagem utilizada em relatórios corporativos pode ser mais preditiva do que os números em si, desde que devidamente interpretada.

Ranco *et al.* (2015) analisaram a relação entre volume de *tweets* e movimentações em ações, mostrando que menções frequentes a determinadas empresas antecedem, com frequência, variações abruptas de preço, o estudo sugere que o PLN aplicado a dados de redes sociais, com monitoramento em tempo real, pode funcionar como ferramenta estratégica para detectar sinais de mercado emergentes.

No contexto institucional, o trabalho de López de Prado (2018) demonstra como fundos quantitativos e bancos de investimento têm utilizado arquiteturas avançadas de PLN, como o FinBERT (modelo baseado em transformers, treinado especificamente para textos financeiros), com o objetivo de melhorar a acurácia preditiva de algoritmos e reduzir o ruído das análises tradicionais.



Com a evolução de modelos de *deep learning*, especialmente redes neurais como LSTM (Hochreiter & Schmidhuber, 1997) e transformers como o BERT (Devlin *et al.*, 2018), o PLN passou a lidar melhor com dependências semânticas e contexto textual, resultando em classificações mais precisas de sentimentos e intenções do mercado.

No entanto, a literatura também aponta limitações importantes. O'Neil (2016) alerta para os riscos de viés algorítmico, ao passo que Doshi-Velez e Kim (2017) discutem o desafio da explicabilidade dos modelos de IA, especialmente em domínios como o financeiro, onde decisões automatizadas podem impactar significativamente pessoas e instituições.

Portanto, os estudos teóricos convergem para o entendimento de que os resultados derivados da aplicação de PLN em finanças não devem ser interpretados isoladamente, mas contextualizados em um cenário mais amplo de análise multidimensional, considerando aspectos técnicos, comportamentais e éticos.

5. Conclusão

Este estudo teve como objetivo analisar, sob uma perspectiva teórica, o potencial do Processamento de Linguagem Natural (PLN) na previsão de tendências no mercado financeiro, destacando suas aplicações, técnicas envolvidas e integração com modelos preditivos contemporâneos.

A partir da revisão da literatura especializada, constatou-se que o PLN representa uma inovação disruptiva em relação aos métodos tradicionais de análise financeira, ao permitir o tratamento de dados não estruturados, como textos jornalísticos, relatórios corporativos e postagens em redes sociais, com significativa capacidade preditiva.

As contribuições teóricas revisadas indicam que técnicas como análise de sentimentos, extração de padrões linguísticos e modelagem preditiva baseada em *deep learning* (como LSTM e BERT) oferecem aos investidores e



instituições ferramentas mais refinadas para interpretar sinais do mercado em tempo real, especialmente diante de eventos inesperados ou de natureza comportamental.

Além de apresentar vantagens na antecipação de movimentos de ativos, o uso do PLN contribui para a democratização do acesso à informação analítica, à medida que torna possível automatizar processos anteriormente dependentes de interpretação humana subjetiva.

No entanto, os autores também alertam para limitações éticas e técnicas, como o viés algorítmico, a complexidade interpretativa dos modelos e a necessidade de rigor na curadoria dos dados utilizados.

Dessa forma, este estudo reforça a importância da integração interdisciplinar entre finanças, ciência de dados e inteligência artificial, propondo que o avanço do uso de PLN no mercado financeiro seja acompanhado de reflexão crítica, desenvolvimento de soluções transparentes e aprofundamento das pesquisas sobre seus impactos práticos e teóricos, fica, portanto, o convite à continuidade da investigação científica neste campo, com enfoque empírico e experimental, a fim de consolidar os benefícios e mitigar os desafios identificados pela literatura.



Referências

ASSAF NETO, Alexandre. **Mercado Financeiro**. 14. ed. São Paulo: Atlas, 2021.

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. Springer, 2006.

BOLLEN, Johan; MAO, Huina; ZENG, Xiaojun. "Twitter mood predicts the stock market". **Journal of Computational Science**, 2011.

DAMODARAN, Aswath. **Investment Valuation: Tools and Techniques for Determining the Value of Any Asset**. 3rd ed. Wiley, 2012.

DEVLIN, Jacob *et al.* **"BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding"**. 2018.

DOSHI-VELEZ, Finale; KIM, Been. **"Towards A Rigorous Science of Interpretable Machine Learning"**. 2017.

FAMA, Eugene. Efficient Capital Markets: A Review of Theory and Empirical Work. **The Journal of Finance**, v. 25, n. 2, 1970.

FABOZZI, Frank J. **Bond Markets, Analysis, and Strategies**. 8th ed. Pearson, 2013.

GITMAN, Lawrence J.; ZUTTER, Chad J. **Princípios de Administração Financeira**. São Paulo: Pearson, 2010.

GRAHAM, Benjamin; DODD, David. **Security Analysis**. McGraw-Hill, 1934.
HULL, John C. **Risk Management and Financial Institutions**. Wiley, 2015.

HU, Mingqing; LIU, Bing; SKIENA, Steven. **"Mining and summarizing customer reviews"**. Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2004.

KEARNEY, Colm; LIU, Shaojia. "Textual sentiment in finance: A survey of methods and models". **International Review of Financial Analysis**, v. 33, 2014.

LÓPEZ DE PRADO, Marcos. **Advances in Financial Machine Learning**. Wiley, 2018.



MALKIEL, Burton G. **A Random Walk Down Wall Street**. 12th ed. W.W. Norton & Company, 2019.

MURPHY, John J. **Technical Analysis of the Financial Markets**. New York: New York Institute of Finance, 1999.

SHILLER, Robert J. **Irrational Exuberance**. Princeton University Press, 2003.

TSAY, Ruey S. **Analysis of Financial Time Series**. 3rd ed. Wiley, 2010.

YANG, Yichong *et al.* "FinBERT: A Pretrained Language Model for Financial Communications". **arXiv:2006.08097**, 2020.

ZHANG, Rui *et al.* "Stock Movement Prediction from Tweets and Historical Prices". **ACM Transactions on Information Systems**, 2020.